Manual para el curso Modelos Lineales Avanzados (XS-0125) Primer Examen

Anderson Martínez, Sebastián Calvo, Justin Zhu, Fabián Almirall

Contents

1 Modelos Mixtos **2**
1.1 Efectos fijos . . . 2
1.2 Efectos aleatorios . . . 2
1.3 Ejemplo de las escuelas . . . 2
1.4 En resumen: . . . 4

2 Tipos y estructuras de datos **4**

3 Diferencia entre un modelo con bloques y un modelo mixto. **4**

4 Parcelas divididas **4**

5 Diferencias entre modelo mixto y modelo lineal clásico. **5**

6 Modelos lineales mixtos **5**
6.1 Sobre los supuestos . . . 5

7 El modelo **5**
7.1 Distribuciones del modelo . . . 6
7.1.1 Apuntes importantes de los errores . . . 6
7.1.2 Distribuciones de cada nivel . . . 6
7.1.3 ¿Cuándo se nos habla de verificar la normalidad a que se refiere? . . . 7
7.2 Componentes de la varianza . . . 8
7.3 Coeficiente de correlación intraclase (ICC) . . . 8

8 Modelo con Interacción **9**
8.1 Gráficos de interacción . . . 9
8.2 Modelo con interacción en r {lm_int} . . . 11
8.3 Comparación de modelos con y sin interacción . . . 11
8.4 Esperanza marginal del factor de la unidad de nivel 2 . . . 12
8.5 Componenetes de la varianza . . . 13

9 Prueba de razón de verosimilitud **13**

10 Estimación de modelos mixtos en r **14**
10.1 Estimaciones manuales mediante un modelo lineal . . . 15
10.2 Intervalos de confianza para las varianzas . . . 15
10.2.1 Código para las diferencias entre intervalos de confianza . . . 16
10.2.2 Simulación de intervalos de confianza . . . 16
10.3 Intervalos de confianza para las diferencias de diferentes categorías . . . 17
10.3.1 Hipótesis sobre la diferencias entre categorías . . . 18

10.3.2 Intervalos de confianza mediante la función emmeans 19
10.3.3 Comparaciones para el nivel de significancia α cuando se usa emmeans (Bonferroni) . 19
10.3.4 Proceso manual para la creación de intervalos de confianza 19

1 Modelos Mixtos

1.1 Efectos fijos

- En un factor de efectos fijos el interés está sólo en aquellos niveles que están siendo usados en el experimento y sus efectos. Todas las conclusiones de están limitadas a los tratamientos que están siendo observados en el experimento.
- Se asume que el experimentador ha considerado para el factor todos los posibles niveles que éste puede tomar o se escogieron deliberadamente, no de forma aleatoria.
- Ejemplo: la temperatura (10º, 16º, 27º) sería un factor fijo si esas fueran las únicas temperaturas de interés para el investigador.

1.2 Efectos aleatorios

- En un factor de efectos aleatorios se asumen que se ha considerado tan solo una muestra de los posibles niveles que éste puede tomar.
- El efecto que tiene cada nivel de ese factor se considera proveniente de una distribución de efectos cuya esperanza es cero.
- Los efectos de los niveles escogidos son aleatorios en el sentido de que son una muestra de esa distribución de efectos.

1.3 Ejemplo de las escuelas

ATENCIÓN AL SIGUIENTE EJEMPLO EXPUESTO EN CLASE

Ejemplo: La escuela es analizada como un factor que puede influir sobre el nivel de aprendizaje y se han considerado en el experimento solo 10 de las muchas escuelas posibles. La escuela es un factor aleatorio en el experimento y sus efectos provienen de una distribución.Además se toma en cuenta otro factor sobre si la escuela es privada o pública.

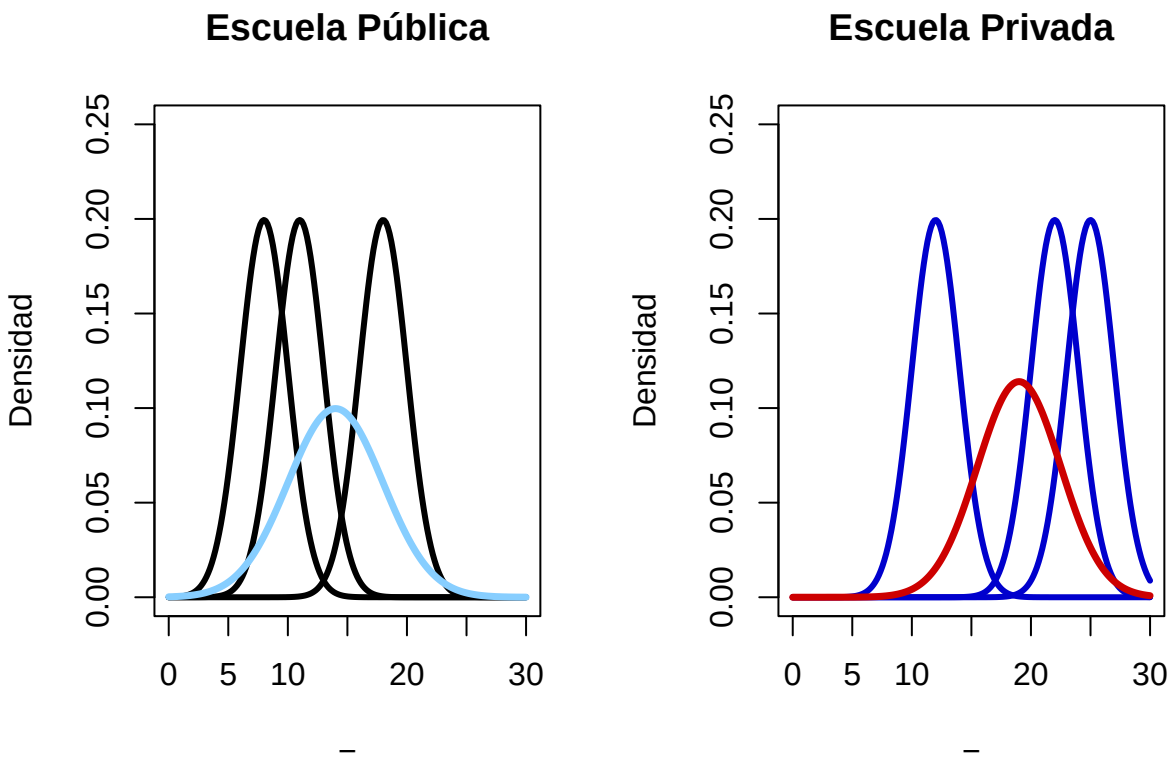

Descripción del gráfico

Negro: La distribución de los grupos de una escuela pública.

Azul: La distribución de los grupos de una escuela privada .

Celeste: La distribución de las escuelas públicas.

Rojo: La distribución de las escuelas privadas.

Unidades del nivel 1

Son los grupos de las escuelas, las distribuciones de este nivel son las de color **Negro** y **Azul**. Es decir cada distribución corresponde a una escuela.

- La variable respuesta (Y) se mide en el nivel 1,la distribución es la siguiente $f(Y|\text{Escuela})$
- μ_j: Es el promedio de una escuela (una distribución negra o azul). Todas las μ_j se unen y forman las curvas de los colores **Celeste** y **Rojo**
- σ_j^2: Es la varianza del error, esta se encuentra en el nivel 1.
- Debido a la homocedasticiadad podemos asumir que σ_j^2 es constante.

Unidades del nivel 2

Este nivel corresponde a las medias de todas las escuelas, cada tipo de escuela tiene una distribución, **Celeste** para las escuelas pública y **Rojo** para las escuelas privadas. Puede ser que las varianzas de estas distribuciones sean iguales, pero no necesarimente sucede ese caso, de hecho es muy utópico pensar que todo tenga la misma varianza.

- Los μ_j son los que forman las distribución en el nivel 2

- La forma de la distribución es $f(\mu_j|\text{Tipo de escuela})$

Conceptos importantes

Error: Es la distancia de un punto de la distribución a su media, por ejemplo imagine un punto de una de las distribuciones negras a su media.

Efecto: Un ejemplo de efecto es la distancia entre la media de una de las distribuciones **negras** con la media de la distribución **celeste**. Como hay escuelas infitas, esto implica que hay efectos infinitos.

Sea γ el efecto, este se distribuye como $\gamma \sim f(0, \sigma_\gamma^2)$. Para cada uno de los tipos de escuelas hay infinitos efectos con una cierta varianza, en donde ambos tipos de escuela pueden tener la misma.

1.4 En resumen:

- Efectos fijos son los factores
- Efectos aleatorios son las unidades

Cuando las unidades están en el nivel 1, los experimentos son como los del curso pasado, en cambio cuando estas unidades se encuentran del nivel 2 hacia arriba a esto le llamaremos como un modelo mixto. Estos corresponden a lo que se llama un modelo multinivel.

Notas:

- Normalmente a los efectos aleatorios se le asigna un factor fijo
- La unidad normalmente contiene efectos aleatorios.
- Siempre tienen que haber unidades aleatorias en el nivel 1

2 Tipos y estructuras de datos

Datos agrupados	**Medidas repetidas**	**Datos longitudinales**
* La variable dependiente se mide una vez por cada sujeto.	* La variable dependiente se mide más de una vez en la misma unidad de análisis.	* La variable dependiente se mide en muchos momentos a lo largo del tiempo, para cada unidad de análisis.
* Las unidades de análisis se agrupan (clusters de unidades).	* La medición se realiza en varios niveles de un factor de medidas repetidas.	

3 Diferencia entre un modelo con bloques y un modelo mixto.

Es un modelo mixto, cuando hay dos factores o más en el nivel 1, en un diseño de dos niveles o más. Por el contrario cuando hay dos niveles, pero el nivel 1 solo tiene un factor es un diseño de bloques. Además si hay un factor en el nivel dos, también hay que usar modelos mixtos.

4 Parcelas divididas

Cuando el diseño es de dos niveles con un factor en cada nivel, al mismo se le puede llamar como parcelas divididas. Un ejemplo de esto sería un experimento que quiere comparar el crecimiento de dos especies de papá en dos tipos de clima. En donde se siembran dos especies de papas en fincas que se encunetran en un clima frió y en otras que tienen un clima caliente.

5 Diferencias entre modelo mixto y modelo lineal clásico.

- El modelo de regresión lineal simple requiere de formular muchos supuestos para que su uso sea adecuado.
- Los modelos lineales mixtos permiten tomar en cuenta la violación a algunos de los supuestos del modelo lineal simple.
- En la práctica, permiten modelar situaciones comunes en las ciencias sociales y en otras ciencias, como la presencia de estructuras jerárquicas.
- Los Modelos Lineales Mixtos Generalizados (GLMM) incluyen técnicas de modelación no solo para variables continuas, sino también nominales, ordinales, conteos, respuestas asimétricas, entre otras.

6 Modelos lineales mixtos

Modelos para variables continuas en los que los residuos se distribuyen normalmente, pero podrían no ser independientes o no tener varianza constante.

El término "lineal" proviene del hecho de que estos modelos son lineales en los parámetros.

El término "mixto" es debido a que las covariables pueden incluir un "mix" de efectos fijos y efectos aleatorios.

6.1 Sobre los supuestos

Los modelos mixtos permiten manejar estructuras de variabilidad que no son homogéneas, por lo que se pueden usar cuando hay homocedasticidad. En un ANOVA no se necesita linealidad, en cambio cuando hay covaribales, variables numéricas como en regresión, en los modelos mixtos necesitamos linealidad. Si sucede el caso de que esta última no se da, debemos realizar una transformación.

En un caso extremo donde los datos se comporten de una forma muy extraña, lo que podemos hacer es convertir la variable continua en una forma categórica, de manera que se parte la variable continua y se forman las categorías con dichos intervalos. Además para los modelos mixtos el hecho de que las variables predictoras no estén correlacionadas, lo que conocemos en otros cursos como el supuesto de no multicolinealidad, para que así los errores estándar no se inflen y las variables puedan explicar adecuadamente el modelo.

Hay algunos modelos que no tienen una distribución normal, por lo que se usa una distribución conocida con la que se realiza dicho modelo, debido a que es muy díficil realizar las estimaciones por medio de una distribución normal. Por ejemplo un conteo de autos durante cada hora, el cual normalmente se modela con una Poisson. A esto se le llama Modelos Lineales Gneralizados, los mismo se utlizan cuando la respuesta no es normal, este tema se abordará más adelante en el curso.Por último sino se cumple la independencia de la unidades de la respuesta y esa la variable Y no se comporta como una normal, pasamos a los *Modelos Lineales Mixtos Generalizados*.

Nota: En un experimento la multicolinealidad automáticamente se cumple.

7 El modelo

El efecto de la unidad i-ésima del nivel 2 se denota como: δ_i.

La j-ésima observación dentro de la i-ésima unidad del nivel 2 se puede expresar como:

$$y_{ij} = \beta_0 + \delta_i + \varepsilon_{ij}$$

La esperanza condicional dado la unidad del nivel dos es:

$$E[Y|i] = \mu_i = \beta_0 + \delta_i$$

donde:

- $\beta_0 = \mu$ (Intercepto)
- $\delta_i = \mu_i - \mu$ (Definición de error)

7.1 Distribuciones del modelo

1. Se consideran dos fuentes de variabilidad:

- La variación de unidad del nivel 2 a una unidad del nivel 2 (inter sujeto): σ_δ^2
- La variación entre los datos dentro de una misma unidad de nivel 2.

Tomando como ejemplo el diseño de las escuelas vistas en clase

$$V(Y|\text{escuela}) = V(error)$$

Nota: La definción de error se encuentra arriba.

7.1.1 Apuntes importantes de los errores

- Los errores se distribuyen como $\varepsilon \sim N(0, \sigma_\varepsilon)$
- Debido a que hay homocesticidad podemos juntar a todos los errores. La función de unir todos los errores nos ayuda a observar la normalidad.

7.1.2 Distribuciones de cada nivel

Existen dos en el ejemplo de las escuelas:

$V(\varepsilon)$: Esta corresponde a una varianza por cada escuela, pero si hay homocesasticidad habría solo una. En un caso extremo se puede tener $V(\varepsilon|\text{Pública}) \neq V(\varepsilon|\text{Privada})$

$V(\mu|\text{Tipo de escuela})$: Hay dos una para la escuela pública y otra para la privada. De igual forma si hay homocedasticidad solo habría una, es decir $V(\mu|\text{Pública}) = V(\mu|\text{Privada})$

2. Los efectos de las unidades del nivel 2 son aleatorias y se obtienen de una distribución normal con media cero:

$$\delta \sim \mathcal{N}(0, \sigma_\delta^2)$$

3. La distribución condicional de la respuesta dado la unidad del nivel 2 también es normal:

$$Y|i \sim \mathcal{N}(\mu_i, \sigma_\varepsilon^2)$$

4. La variancia total de la respuesta es la suma de la variancia de los componentes aleatorios más la variancia del error:

$$V(Y) = \sigma_\delta^2 + \sigma_\varepsilon^2$$

Nota: Esta suma nos sirve para ver en terminos relativos (%), la variabilidad, normalmente se usa para dar conclusiones. De tal manera que podemos tener estos dos casos $\sigma_\delta^2 < \sigma_\varepsilon^2$ ó $\sigma_\delta^2 > \sigma_\varepsilon^2$. En palabras simples, nos sirve para buscar quien es el culpable de generar mayor variabilidad. *Ver en el índice el ICC sección 7.3*

A continuación se representan las distribuciones por medio de una figura

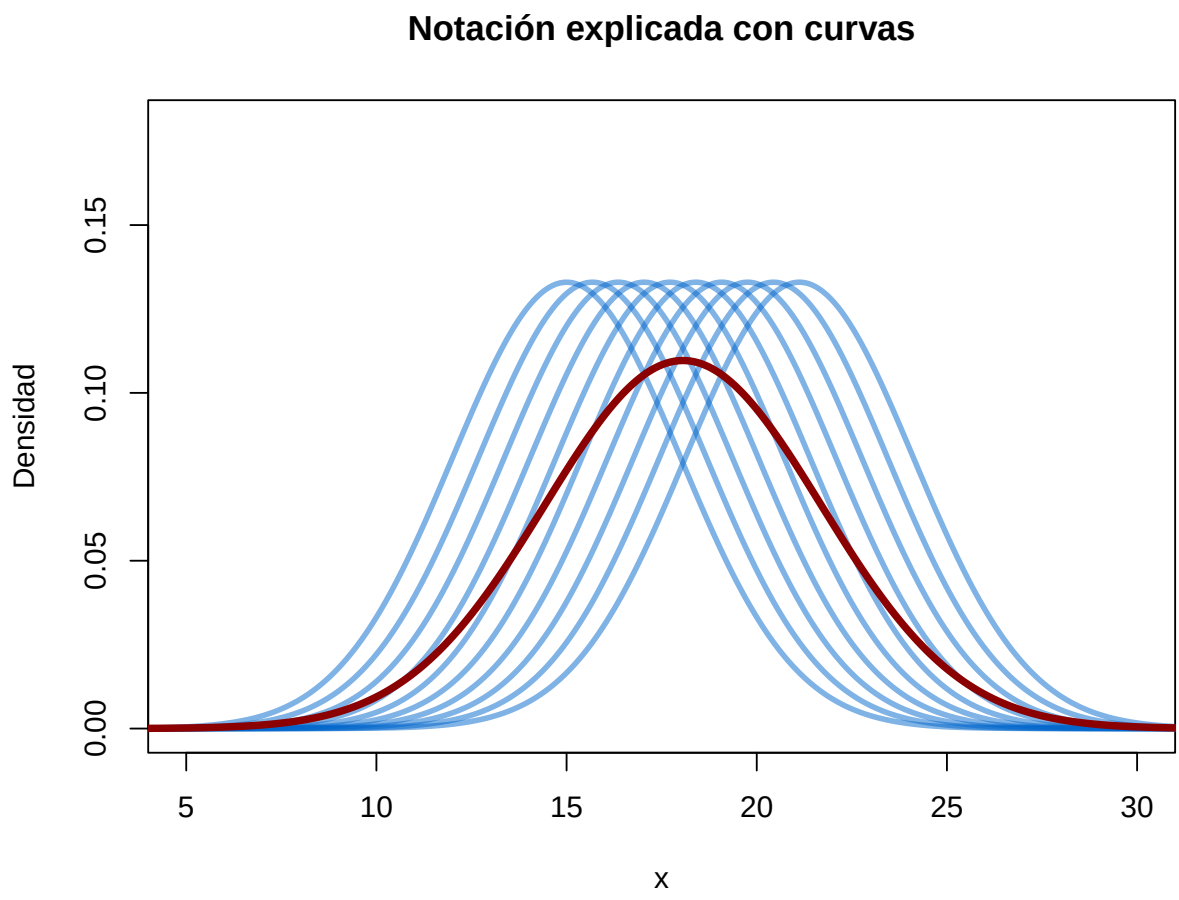

donde:

- **Curvas azules** corresponden a $Y|i \sim N(\mu_i, \sigma_\varepsilon^2)$
- **Curva Roja** corresponde a $\mu_i \sim N(\mu, \sigma^2)$, sin embargo se quiere calcular el efecto que este es $\delta = \mu_i - \mu$, el cual se distribuye como $\delta \sim N(0, \sigma_\delta^2)$.

Nota: Es lo mismo decir $V(\delta_i) = V(\mu_i)$

7.1.3 ¿Cuándo se nos habla de verificar la normalidad a que se refiere?

Se refiere a evaluar el supuesto de normalidad en la distribución $Y|i \sim N(\mu_i, \sigma_\varepsilon^2)$, la explicación de esta la puede encontratrar en la parte de arriba. Si tenemos muy pocos efectos en las muestra y queremos probar normalidad, la debemos asumir porque para probar esto se debe tener una cantidad considerable de observaciones. Sin emabargo podemos unir todos los residuales para probar normalidad en el caso de que se cumple el supuesto de *Homocedasticidad*

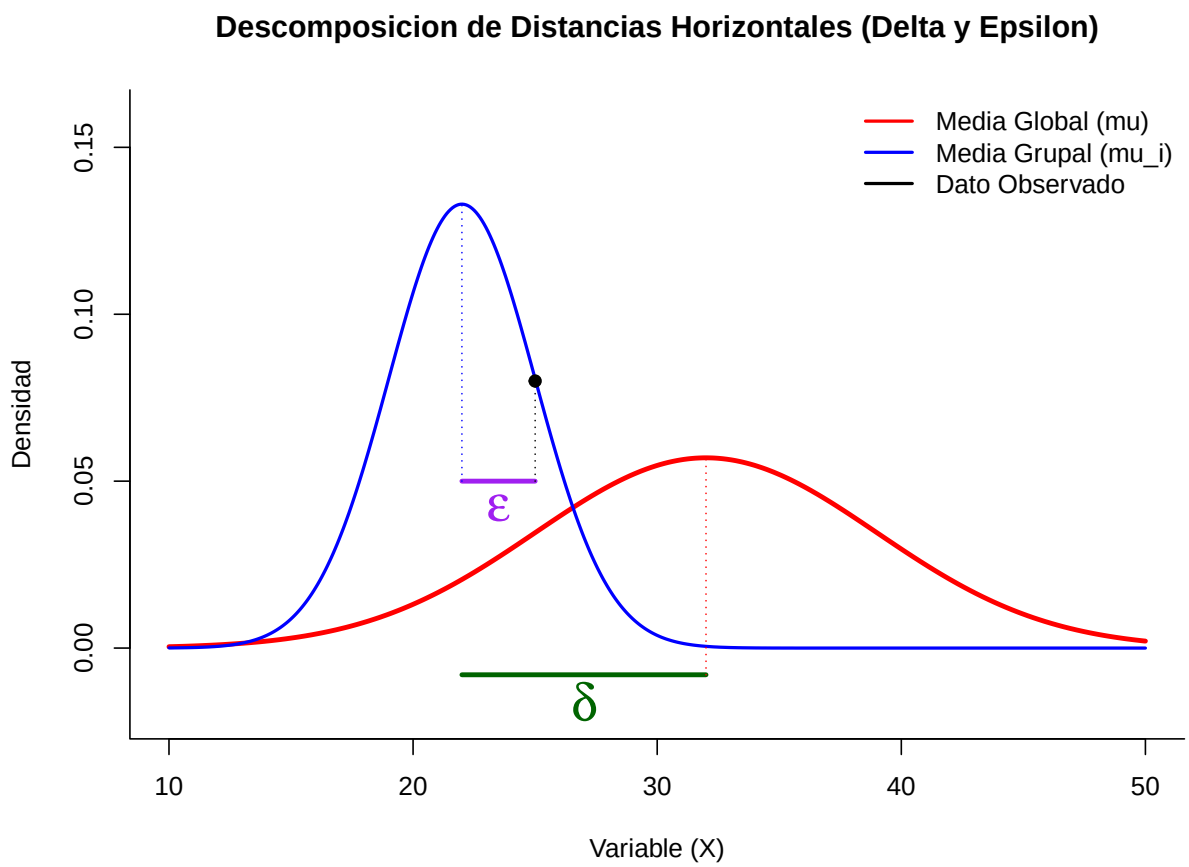

7.2 Componentes de la varianza

- El modelo tiene solo un coeficiente **fijo** que es el **intercepto** o media general, y tiene un componente aleatorio que son los efectos de las unidades del segundo nivel.
- Interesa determinar si hay efecto de las unidades del segundo nivel, pero no interesa estimar la magnitud de los mismos ya que son solo una muestra de una población mayor de unidades infinitas.
- La variancia de cualquier observación se obtiene a partir de dos fuentes: la de unidad de nivel 2 a unidad de nivel 2 (inter sujeto) y la residual (intra sujeto).
- Si realmente hay un efecto de la unidad del nivel 2, la variancia entre unidades del nivel 2 será mayor a cero. Como se denota a continuación:

$$H_0 : \sigma_i = 0$$
$$H_1 : \sigma_i > 0$$

7.3 Coeficiente de correlación intraclase (ICC)

- Es una medida que relaciona la variabilidad entre los grupos con la variabilidad dentro de los grupos.
- Es la proporción de la variación en la variable respuesta que ocurre entre grupos con respecto a la variación total.

- Formalmente: Siendo σ_ε^2 la varianza dentro de los grupos, y siendo σ_δ^2 la varianza entre los grupos, el coeficiente de correlación intraclase (ρ_I) es:

$$\rho_I = \frac{\sigma_\delta^2}{\sigma_\delta^2 + \sigma_\varepsilon^2}$$

Esto nos dice que porcentaje de varibilidad se debe a las unidades del nivel 2. Si hay **baja** variabilidad intra clase $\rho_I \to 0$, quiere decir que las unidades del segundo nivel son muy similares, por el contrario si $\rho_I \to 1$, nos esta diciendo que son muy difentes.

A continuación se le presenta un ejemplo sobre un cálculo en r

```
sigma_delta = 1764
sigma_epsilon = 2451
sigma_delta/(sigma_delta+sigma_epsilon)*100
```

```
## [1] 41.85053
```

Respuesta: El 41.8% de la variabilidad es debida a las unidades del nivel 2.

Si se requiere sacar un intervalo de confianza para las varianzas, se recomienda utilizar estadística Bayesiana.

8 Modelo con Interacción

Una inconsistencia en el factor del nivel 2, es lo que nos sospecha que haya interacción

El efecto de la i-ésimo del factor del nivel 2 se denota con: τ_i

El efecto del j-ésima unidad de nivel 2 se denota con: δ_j

El efecto de interacción para la i-ésimo factor en la j-ésima unidad de nivel 2 se denota con:

A continuación el modelo es explicado, basandosé en el ejemplo de las máquinas vistas en clase

La k-ésima muestra dentro del j-ésimo día, para la i-ésima máquina se puede expresar como:

$$y_{ijk} = \beta_0 + \tau_i + \delta_j + (\tau\delta)_{ij} + \varepsilon_{ijk}$$

La esperanza condicional dado la unidad de nivel 2 y el factor del mismo nivel, se denota de la siguiente manera:

$$E[Y|ij] = \mu_{ij} = \beta_0 + \tau_i + \delta_i + (\tau\delta)_{ij}$$

Notas:

- $\delta_j = \mu_j - \mu$, es decir la media de la unidad de nivel 2 menos la media general (media de las medias).
- Los efectos de interacción son infinitos, por lo que son aleatorios.
- τ_i es fijo, ya que este depende de la restricción que elijamos (suma nula o referencia)

8.1 Gráficos de interacción

A continuación se le presenta un ejemplo de como se ve gráficamente un modelo con / sin interacción

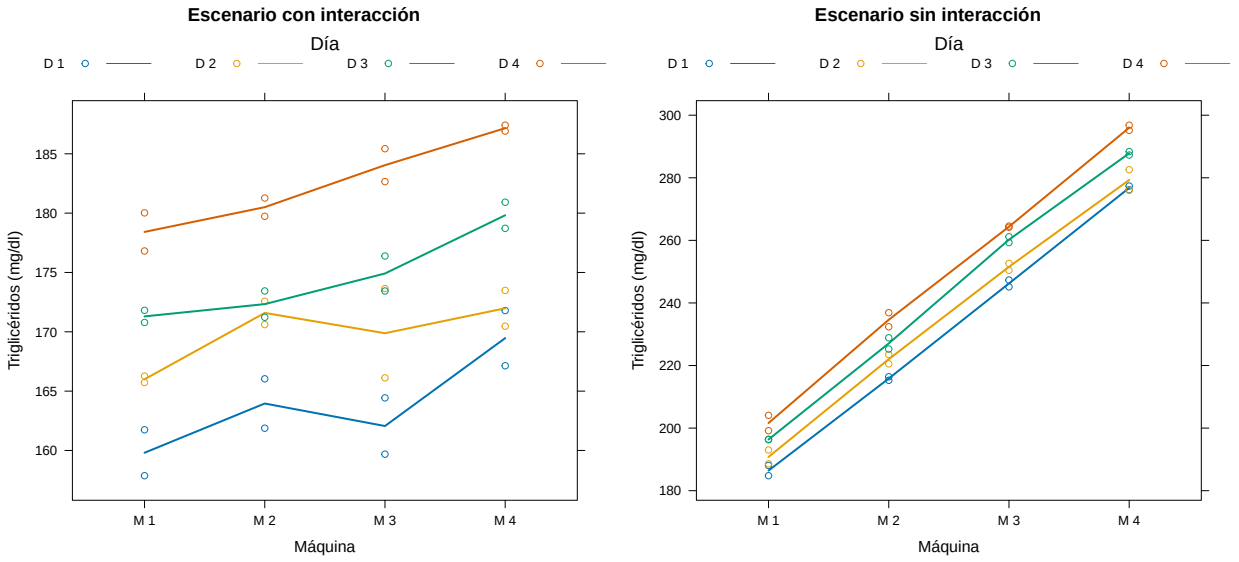

Código para crear el gráfico anterior

```
library(lattice)
xyplot(Y ~ Maquina, groups = Dia, data = datos,
            type = c("p", "a"), lwd=2,
            auto.key = list(columns = 4, title = "Día", cex=0.8),
            main = "Escenario A: CON INTERACCIÓN\n(Tendencias Cruzadas)",
            ylab = "Triglicéridos (mg/dl)", xlab = "Máquina")
```

Gráfico de puntos para la interacción

El siguiente gráfico normalmente se utliza debido a que es una cantidad de observaciones pequeña.

En este experimento se tiene un estudio con 2 niveles con un factor en el nivel 1 , lo que corresponde a lo que conocemos como un diseño de bloques.

Tenenos dos varianzas: σ_ε varianza del error la cual corresponde, a la de muestra a muestra dentro de un día y una muestra. Por otro lado σ_δ varianza de los efectos del día.

En ambos gráficos podemos observar que las maquinas no son consistentes (cuando hay interacción), debido a que estas no dan los mismos resultados a lo largo de los días. Por otro lado para el caso sin interacción que las maquinas son bastante consistentes

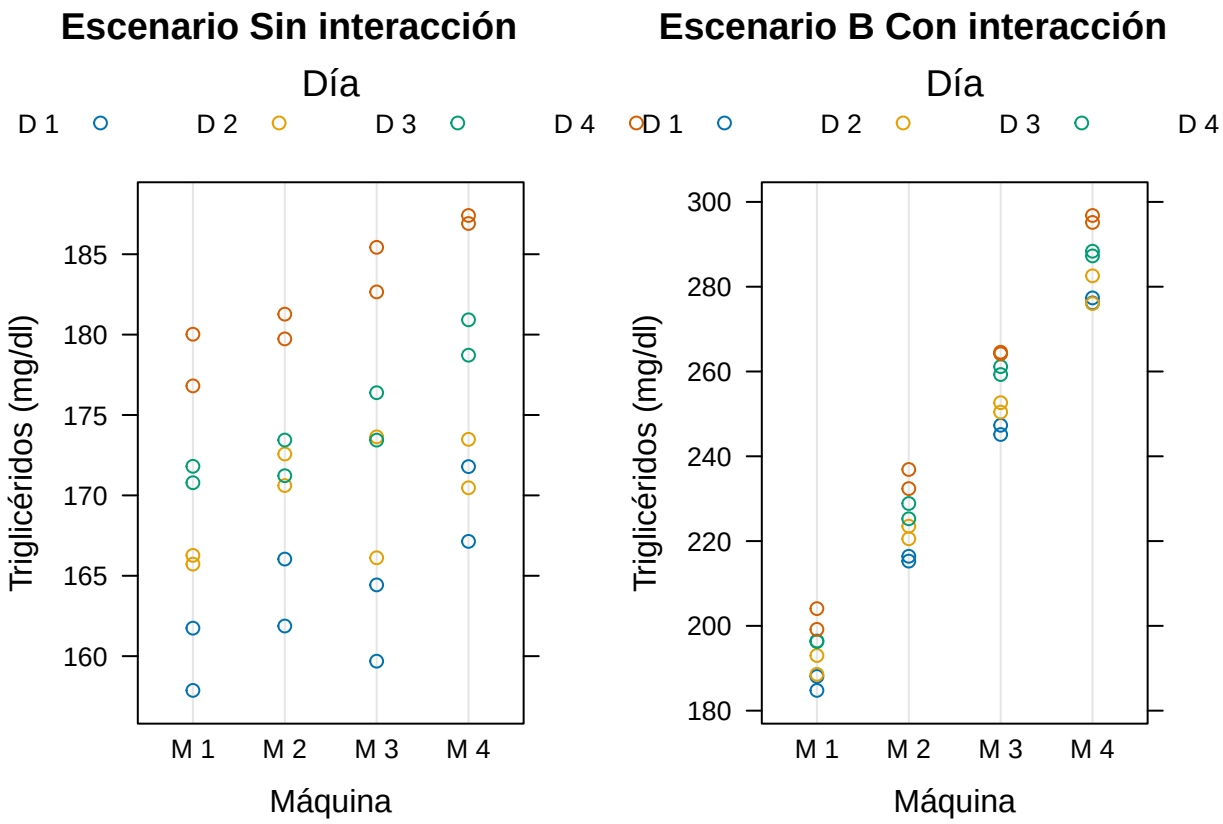


```
dotplot(Trig_NoInt ~ Maquina|Dia,xlab="día",ylab="triglicéridos", data = datos)
```

8.2 Modelo con interacción en r {lm_int}

```
library(lme4)
```

```
## Loading required package: Matrix
```

```
mod1=lmer(trigli~1+maq+(1|dia)) #Código de modelo sin interacción
mod1_int=lmer(trigli~1+maq+(1|dia)+(1|dia:maq))
```

Observe que la interacción se coloca con `:`, de manera que se coloca con esta indicación `(1|dia:maq)`. Recuerde que los factores aletorios se colocan así `(1|factor)`.

8.3 Comparación de modelos con y sin interacción

Para verificar si hay interacción o no, necesitamos probar la siguiente hipótesis:

$$H_0 : \sigma^2_{\tau\delta} = 0 \quad \text{(No existe interacción)}$$
$$H_1 : \sigma^2_{\tau\delta} > 0 \quad \text{(Existe interacción significativa)}$$

Esta hipótesis se puede realizar mediante el método realizado en la sección de La prueba de la razón de verosimilitud

En r se realiza de la siguiente manera

```r
anova(mod1, mod1_int, test = "LRT")
```

```
## refitting model(s) with ML (instead of REML)
```

```
## Data: NULL
## Models:
## mod1: trigli ~ 1 + maq + (1 | dia)
## mod1_int: trigli ~ 1 + maq + (1 | dia) + (1 | dia:maq)
##          npar    AIC    BIC  logLik -2*log(L)  Chisq Df Pr(>Chisq)
## mod1        6 228.12 236.92 -108.06    216.12
## mod1_int    7 224.39 234.65 -105.19    210.39 5.7338  1    0.01664 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
# También se puede de esa manera anova(mod1, mod1_int, test = "Chisq")
#, depende de la versión del R
```

```r
summary(mod1)
```

```
## Linear mixed model fit by REML ['lmerMod']
## Formula: trigli ~ 1 + maq + (1 | dia)
##
## REML criterion at convergence: 200
##
## Scaled residuals:
##      Min       1Q   Median       3Q      Max
## -2.09185 -0.43598 -0.08414  0.64558  2.27517
##
## Random effects:
##  Groups   Name        Variance Std.Dev.
##  dia      (Intercept) 50.24    7.088
##  Residual             42.89    6.549
## Number of obs: 32, groups:  dia, 4
##
## Fixed effects:
##             Estimate Std. Error t value
## (Intercept)  147.000      4.233  34.724
## maqB           1.800      3.275   0.550
## maqC          -9.075      3.275  -2.771
## maqD         -15.987      3.275  -4.882
##
## Correlation of Fixed Effects:
##      (Intr) maqB   maqC
## maqB -0.387
## maqC -0.387  0.500
## maqD -0.387  0.500  0.500
```

Observe que la variancia de día a día es 50.24 y la variancia residual es 42.89.

8.4 Esperanza marginal del factor de la unidad de nivel 2

En un modelo sin interacción podemos tener la siguiente esperanza:

$$E[E[Y|ij]] = \mu_{i*} = \beta_0 + \tau_i$$

8.5 Componenetes de la varianza

Se consideran tres fuentes de variabilidad:

- La variación entre unidades de nivel 2 (inter sujeto): σ_δ^2
- La variación entre los datos dentro de una misma unidad de nivel 2 dentro del mismo factor (intra sujeto): σ_ε^2
- La variación de interacción: $\sigma_{\tau\delta}^2$

Como el intercepto β_0 y el efecto del factor τ_i es fijo esto nos lleva a que la varianza total es:

$$V(Y|i) = \sigma_i^2 = \sigma_\delta^2 + \sigma_{\tau\delta}^2 + \sigma_\varepsilon^2$$

9 Prueba de razón de verosimilitud

Definición de la verosimilitud creada en la clase: *La verosimilitud es que tan creíble la estimación de un parámetro, basado en los datos de la muestra. Con el objetivo de dar una medida de la credibilidad de la estimación.*

Esta nos sirve para probar la hipótesis relativa a la variancia del componente aleatorio de interacción: $H_0 : \sigma_\delta^2 = 0$ contra la alternativa: $H_1 : \sigma_\delta^2 > 0$.

Aunque la hipótesis se plantea en términos de una restricción para el parámetro, hay que tener presente que lo que se compara es la calidad del ajuste obtenido con **dos modelos anidados**. La prueba de la razón de verosimilitud (LRT) equivale a la diferencia de las devianzas de los dos modelos que se comparan (la fórmula está más abajo).

El estadístico LRT usa como distribución de referencia aproximada una chi-cuadrado con grados de libertad equivalente a la diferencia en el número de parámetros de ambos modelos.

A continuación se le presenta la fórmula

$$\begin{aligned}
\chi^2_{(\nu)} &= D_\omega - D_\Omega \\
&= -2\log(\mathcal{L}_\omega) - (-2\log(\mathcal{L}_\Omega)) \\
&= -2\log\left(\frac{\mathcal{L}_\omega}{\mathcal{L}_\Omega}\right)
\end{aligned}$$

donde:

- Los ν es la diferencia del número de parámetros de los dos modelos
- D_ω: devianzia del modelo pequeño
- D_Ω: devianzia del modelo grande
- $\mathcal{L}_\omega$: valor de la máxima verosimilitud del modelo ω con los parámetros que la maximizan.Lo mismo para $\mathcal{L}_\Omega$
- $\frac{\mathcal{L}_\omega}{\mathcal{L}_\Omega}$ es la razón de las verosimilitudes **Esto es el LRT**

En este caso el valor-p obtenido debe tomarse con cautela ya que el parámetro que se prueba está en el borde del dominio de posibles valores para el parámetro.

El valor-p será conservador en el sentido de que será mayor que el valor-p que se obtendría en simulaciones.

En el peor de los casos el valor-p será el doble de lo que debería ser.

Ejemplo:

Tenemos los siguientes modelos:

Modelo 1:

$y_{ij} = \beta_0 + \beta_1 X_1 + \delta_i + \varepsilon_{ij}$

Modelo 2:

$y_{ijk} = \beta_0 + \beta_1 X_1 + \tau_k + \delta_i + \varepsilon_{ijk}$

donde: τ es un factor con tres niveles

Para el **modelo 1**:

- 2 parámetros fijos(β_0, β_1)
- 2 parámetros aleatorios $(\sigma^2_\delta, \sigma^2_\varepsilon)$

Para el **modelo 2**:

- 4 parámetros fijos$(\beta_0, \beta_1, \tau_1, \tau_2)$
- 2 parámetros aleatorios $(\sigma^2_\delta, \sigma^2_\varepsilon)$

Note que para el modelo 2 se usa suma nula. Por lo que $\sum \tau_i = 0$

Si se comparan estos dos modelos sería con la siguiente fórmula:

$$\chi^2_{(\nu)} = D_\omega - D_\Omega \sim \chi^2_{(2)}$$

Con esto podemos probar la siguientes hipótesis:

$$\begin{cases} H_0 : \tau_1 = \tau_2 = 0 \\ H_1 : \text{Al menos un } \tau_i \neq 0 \end{cases}$$

Con esto podemos concluir que las medias condicionales son iguales para los dos niveles del factor de los τ.Esto nos sirve para ver si las medias son iguales o distintas de dos modelos.

Si yo quiero probar el coeficiente δ_j, para ver si es importante que se encuentre en el modelo no lo puedo hacer con la función `drop1()`, así como se puede hacer con el factor del ejemplo anterior. Por ello para probar la hipótesis al inicio de esta sección se necesita el LRT. Normalmente este caso en específico se usa para observar si es necesario realizar o utilizar bloques en un experimento.

10 Estimación de modelos mixtos en r

```
library(lme4) #librería para modelos mixtos
```

```
mod1=lmer(prod~(1|lote),data=base)
```

```
mod1.2=lmer(prod~(1|lote),data=base, REML = F) #Modelo con la  máxima verosimilitud no restringida
```

Notas: El `REML` *Máxima Verosimilitud Restringida.* Además al ser un modelo sencillo el β_0 es igual a la media observada.

Con respecto al modelo `REML`, debido a que en los modelos mixtos se utlilizan muchos parámetros para la estimación de máxima verosimilitud, lo que se realiza es fijar uno de los parámetros, para maximizar todos, para así de esa manera ir realizando combinaciones y como resultado se obtiene la máximización de todos. Puede ser que por este método de lo mismo que cuando se máximizan todos los paramétros al mismo tiempo.

10.1 Estimaciones manuales mediante un modelo lineal

Para poder explicar este tema se usa el siguiente caso de **Colorantes** en donde se tiene un solo factor aleatorio que son lotes de producción, y se quiere verificar si la variabiliad existente entre los promedios de los lotes es mucho mayor que la variabilidad del error.

```
mod2=lm(prod~lote,data=base)
anova(mod2)
```

Primero se debe tener claro este concepto:

$$
\begin{aligned}
&V[\mu_i] = V[\mu + \delta_i] \\
&V[\mu_i] = V[\mu] + V[\delta_i] \quad \text{donde } V[\mu] = 0 \\
&V[\mu_i] = \sigma_\delta^2
\end{aligned}
$$

Se parte de las esperanzas de los cuadrados medios:

$$E[CMLote] = \sigma_\varepsilon^2 + n\sigma_\delta^2$$

$$E[CMRes] = \sigma_\varepsilon^2$$

Se empieza estimando $\sigma_\varepsilon^2 psilon$ con el CMRes y se sustituye en la primera ecuación:

$$CMLote = CMRes + n\sigma_\delta^2$$

Por lo tanto:

$$\hat{\sigma_\delta^2} = \frac{CMLote - CMRes}{n}$$

10.2 Intervalos de confianza para las varianzas

`{r. eval = False} confint(mod1)`

Nota: Se le llama `sigma` a la desviación estándar del error, `sig01` es la del lote. Para obtener la varianza recuerde elevar al cuadrado los resultados. Además note que los intervalos no son simétricos, debido a que el $\pm$ en el intervalo de confianza de varianzas no se utliza. Si el limite inferior da cero quiere decir que el interavlo no se tuvo que haber realizado, debido a que la varianza puede ser cero.

Simulación de los deltas (Forma1)

```
sd.lote=42 #sigma delta
n=6 #Número de lotes
med=1500
ef.lote=rnorm(n,0,sd.lote) #simulación de los deltas
(muj=med+ef.lote)
```

```
## [1] 1469.454 1554.707 1514.106 1543.617 1538.671 1530.277
```

Simulación de los deltas (Forma2, un poco más directa)

```
sd.lote1=42 #sigma delta
n=6 # Número de lotes
med=1500
(muj.2=rnorm(n,med,sd.lote1)) #simulación de los deltas
```

```
## [1] 1456.189 1496.212 1526.188 1459.952 1477.201 1524.402
```

Simulación de la respuesta

```
n = 6
sd.res = 49.51
r = 5 # Número de observaciones por lote
mujs = rep(muj,each=r)
y = rnorm(n*r,mujs,sd.res)
```

Obtener los efectos alteatorios (δ) de forma directa

```
deltas = ranef(mod)
```

Para crear la variable Lote (la variable del nivel 2), se realiza de la siguiente manera

```
Lote2 = factor(rep(1:n, each = r))
```

10.2.1 Código para las diferencias entre intervalos de confianza

```
ci = confint(mod)
ci = t(ci)
diff(ci)
```

Con esta diferencia podemos ver potencia,el ancho del intervalo. Para ello se tiene que simular varias veces y guardar esos resultados, para analizar cada uno de los casos anteriores. Para al final sacar el promedio del ancho del intervalo. De manera que cambiando `r` y `n` se llegue a un ancho del intervalo deseado.

10.2.2 Simulación de intervalos de confianza

```
n=6       # Número de Lotes (Nivel 2)
r=5         # Unidades por Lote (Nivel 1)
k=10    # Cuántas de iteraciones

sd.res=49.51
muj=1500     # Media global de referencia
anchos=numeric(k) # Vector vacío para guardar los resultados, de forma más rápida

for(i in 1:k) {
  # 1. Generamos los efectos de los lotes
  # Suponemos una desviación estándar entre lotes
  sd.lote=15
  efectos_lote=rnorm(n, 0, sd.lote)

  # 2. Generamos la respuesta
  mujs=rep(muj + efectos_lote, each = r)
  y=rnorm(n * r, mujs, sd.res)
  Lote2=factor(rep(1:n, each = r))

  # 3. Ajustamos el modelo y calculamos el IC
  # Se usa Wald y parm para que sea rápido en las 100 iteraciones
  mod1.3=lmer(y ~ 1 + (1|Lote2), control = lmerControl(calc.derivs = FALSE))
  CI=confint(mod1.3, parm = "(Intercept)", method = "Wald")

  # 4. Guardamos la diferencia (el ancho)
  anchos[i]=diff(as.vector(CI))
```

```
}
```

```
## boundary (singular) fit: see help('isSingular')
## boundary (singular) fit: see help('isSingular')
## boundary (singular) fit: see help('isSingular')
## boundary (singular) fit: see help('isSingular')
## boundary (singular) fit: see help('isSingular')
```

```
promedio_ancho=mean(anchos)

print(c("El promedio del ancho es",round(promedio_ancho,3)))
```

```
## [1] "El promedio del ancho es" "38.996"
```

10.3 Intervalos de confianza para las diferencias de diferentes categorías

Estos intervalos los podremos realizar, siempre y cuando el modelo que estemos analizando no posea interacción, ya que si la tiene el analisis es distintos, debido a que en estos modelos podemos tener unidades inifinitas dependiendo del factor que se este analizand.

Para este tema usaremos el modelo **sin interacción** presentado en la sección de Modelo con interacción en r

```
summary(mod1)
```

```
## Linear mixed model fit by REML ['lmerMod']
## Formula: trigli ~ 1 + maq + (1 | dia)
##
## REML criterion at convergence: 200
##
## Scaled residuals:
##      Min       1Q   Median       3Q      Max
## -2.09185 -0.43598 -0.08414  0.64558  2.27517
##
## Random effects:
##  Groups   Name        Variance Std.Dev.
##  dia      (Intercept) 50.24    7.088
##  Residual             42.89    6.549
## Number of obs: 32, groups:  dia, 4
##
## Fixed effects:
##             Estimate Std. Error t value
## (Intercept)  147.000      4.233  34.724
## maqB           1.800      3.275   0.550
## maqC          -9.075      3.275  -2.771
## maqD         -15.987      3.275  -4.882
##
## Correlation of Fixed Effects:
##      (Intr) maqB   maqC
## maqB -0.387
## maqC -0.387  0.500
## maqD -0.387  0.500  0.500
```

Observe que `maqB = 1.8`, esto quiere decir que la maquina B es 1.8 puntos mayor que la máquina A, esto es debido a que estamos con el modelo de tratamiento de referencia y esa medida corresponde al efecto de la maquina B que se calcula de la siguiente manera $\alpha_b = \mu_b - \mu_a$. Es importante resaltar que la máquina que tiene menor media es la D. Recuerde que la restricción de referencia es $\alpha_1 = 0$

```r
confint(mod1)
```

```
## Computing profile confidence intervals ...
```

```
##                  2.5 %     97.5 %
## .sig01        2.903589  15.684370
## .sigma        4.863709   8.245133
## (Intercept) 138.251867 155.748123
## maqB         -4.478779   8.078779
## maqC        -15.353779  -2.796221
## maqD        -22.266279  -9.708721
```

Al observar el intervalo de 95% de confianza se tiene que la desviación estándar de día a día está entre 2.9 y 15.7. Esto confirma que esta fuente de variabilidad es importante. Por lo tanto, hay evidencia que hay fuentes de variabilidad que deben revisarse para que este modelo de espectofotómetro funcione mejor. Se esperaría mayor consitencia de uno a otro día.

10.3.1 Hipótesis sobre la diferencias entre categorías

Basado en el mismo ejemplo de la sección anterior queremos probar lo siguiente:

$$H_0 : \alpha_i = 0 \forall_i \text{ ó } \alpha_2 = \alpha_3 = \alpha_3$$

La función `drop1` nos sirve para probar si las medias de las 4 maquinas son iguales que es lo mismo que probar si los efectos de las 4 maquinas son iguales a cero.

```r
drop1(mod1,test="Chisq")# En este caso, nos sirve para probar un factor fijo.
```

```
## Single term deletions
##
## Model:
## trigli ~ 1 + maq + (1 | dia)
##        npar    AIC    LRT   Pr(Chi)
## <none>      228.12
## maq       3 248.18 26.058 9.275e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
#drop1(mod1_int,test="Chisq") # ESTE CÓDIGO ESTA MAL, YA QUE drop1, SOLO SIRVE PARA FIJOS
```

En el resultado la línea de `maq` es la prueba que nos sirve para probar si las medias de las 4 máquinas son iguales, que es lo mismo que probar que los efectos de las máquinas son iguales a cero **Ver hipótesis inicial**.

Para la calcularlo a pie

```r
pchisq(26.058,3, lower.tail = F) # Fórmula a pie, para el chisq
```

```
## [1] 9.274407e-06
```

Restamos las devianzas de los modelos y ese valor lo colocamos en el siguiente código en lugar de `26.058`, el número `3` son los grados de libertad porque el modelo que incluye máquina tiene 3 coeficientes más que el que no tiene este factor, son 3 coeficientes porque son 4 máquinas en el experimento.

Conclusión del resultado: Con $p < 0.001$ en la prueba LRT se rechaza esta hipótesis y se concluye que no se están obteniendo los mismos promedios en todas las máquinas.

10.3.2 Intervalos de confianza mediante la función emmeans

Correción de Bomferroni: El profesor recomienda realizar este ya que es más seguro, debido a que se trata de un modelo mixto

```r
library(emmeans)
```

```
## Warning: package 'emmeans' was built under R version 4.5.3
```

```
## Welcome to emmeans.
## Caution: You lose important information if you filter this package's results.
## See '? untidy'
```

```r
em.mod1=emmeans(mod1,pairwise~maq,adjust="bonferroni")
#emmeans(mod1,pairwise~factor_fijo,adjust="bonferroni")
em.mod1
```

```
## $emmeans
##  maq emmean   SE   df lower.CL upper.CL
##  A      147 4.23 4.94      136      158
##  B      149 4.23 4.94      138      160
##  C      138 4.23 4.94      127      149
##  D      131 4.23 4.94      120      142
##
## Degrees-of-freedom method: kenward-roger
## Confidence level used: 0.95
##
## $contrasts
##  contrast estimate   SE df t.ratio p.value
##  A - B       -1.80 3.27 25  -0.550  1.0000
##  A - C        9.07 3.27 25   2.771  0.0623
##  A - D       15.99 3.27 25   4.882  0.0003
##  B - C       10.88 3.27 25   3.321  0.0166
##  B - D       17.79 3.27 25   5.432 <0.0001
##  C - D        6.91 3.27 25   2.111  0.2697
##
## Degrees-of-freedom method: kenward-roger
## P value adjustment: bonferroni method for 6 tests
```

El `p-value` se compara contra α, ya que la función hace la correción de una vez.

Tuckey

10.3.3 Comparaciones para el nivel de significancia α cuando se usa emmeans (Bonferroni)

Tipo de Prueba	Emmeans	A pie (Manual)
Una cola	$\frac{p}{2} < \alpha$	$p < \frac{\alpha}{d}$
Dos colas	$p < \alpha$	$p < \frac{\alpha}{2d}$

10.3.4 Proceso manual para la creación de intervalos de confianza

Dado el siguiente modelo:

$y_{ijk} = \beta_0 + \tau_i + \delta_i$

donde:

- τ_i: Es el efecto de la maquina i-ésima

- δ_i: Ese es el efecto del día (recuerde que este aleatorio)

```r
contrasts(maq)
```

```
##   B C D
## A 0 0 0
## B 1 0 0
## C 0 1 0
## D 0 0 1
```

```r
A=c(0,0,0,0)
B=c(0,1,0,0)
AB=A-B
sqrt(t(AB)%*%vcov(mod1)%*%AB)
```

```
## 1 x 1 Matrix of class "dgeMatrix"
##          [,1]
## [1,] 3.274699
```

```r
C=c(0,0,1,0)
D=c(0,0,0,1)
CD=C-D
sqrt(t(CD)%*%vcov(mod1)%*%CD)
```

```
## 1 x 1 Matrix of class "dgeMatrix"
##          [,1]
## [1,] 3.274699
```

Observe que el error estándar es igual al obtenido en la función `emmeans`.

```r
# Este código se verá bonito en el manual, pero R NO lo ejecutará.
modelo_complejo <- lm(y ~ x1 + x2, data = mis_datos)
```